

Análisis de datos de influenza

Hospitalizaciones y defunciones semanales

Filtrado de los datos


Simbología

- CASOS_SINT = casos sintomáticos
- CASOS_HOSP = casos hospitalizaciones
- CASOS_DEF = casos defunciones

Tabla 1: Resumen de los datos de Influenza

SEMANA_RELATIVA	CASOS_SINT	CASOS_HOSP	CASOS_DEF	FLAG_SINT	FLAG_HOSP
1	134	40	5	observado	observado
2	145	62	8	observado	observado
3	162	71	9	observado	observado
4	125	58	8	observado	observado
5	102	49	3	observado	observado

Inspección de los datos



a) Preprocesamiento

Semanas con datos faltantes o no reportados

Tabla 2: Semanas con al menos uno de los casos etiquetados como sin_reporte


SEMANA_RELATIVA	CASOS_SINT	CASOS_HOSP	CASOS_DEF	FLAG_SINT	FLAG_HOSP
8	62	26	0	observado	observado
14	0	0	0	sin_reporte	sin_reporte
15	0	0	0	sin_reporte	sin_reporte
16	0	0	0	sin_reporte	sin_reporte
17	0	0	0	sin_reporte	sin_reporte

b) Modelo 1 - Interpolación

Interpolaremos los datos utilizando un **spline cubico de Hermite**. Para ello emplearemos la función `PchipInterpolator` de la libreria `SciPy`

Notas i) Para los modelos 1 y 2, la interpolación (y regresión) se realizara en los puntos $x_i = i$ - iésima semana relativa tal que hay casos observados. Por lo tanto el intervalo de los datos será $I = [1, 52]$. Luego cada subintervalo $[i, i + 1]$, $1 \leq i \leq 1$ se subdividira en 7 intervalos igualmente espaciados en los cuales se realizaran las predicciones, del modelo correspondiente, dandonos su curva de interpolación o de regresión.


ii) En cada caso se agregara al dataset una columna adicional con el valor retornado por cada modelo, para cada uno de los casos (SINT, HOSP, DEF) tanto para los etiquetados como observado, como para los etiquetados como `sin_reporte`.



c) Modelo 2 - Regresión Generalizada

Utilizamos un suavizamiento de la serie de tiempo mediante una regresión robusta local ponderada (LOWESS). Este metodo pondera los datos realizando una predicción en el punto x_i de la serie tomando en consideración solo los primeros rN - *simos* vecinos a la derecha de x_i , en donde - N es el tamaño de los datos. - $0 < r \leq 1$ correspond a la fraccion de los datos sobre los que queremos ponderar respecto a cada x_i . El valor de r se escoge segun sea

conveniente, por ejemplo, disminuyendo los valores residuales. Para este caso utilizaremos el valor de $r = 0.5$ como deefault, lo cual corresponde a ponderar sobre la mitad de los datos.



d) Errores de Estimación

Dado que nos interesa saber que tan bien se ajusta la interpolación y la regresión a nuestros datos observados, conviene saber que tan dispersos estan de la curva obtenida. Por lo que utilizaremos la Raíz del Error Cuadrático Medio (**RMSE**)

$$\sqrt{\frac{1}{n} \sum (\hat{y}_i - y_i)^2}$$

La cual nos da la desviación estandar de los valores residuales. Notemos que en el caso del Modelo 1, que consistio en interpolar los datos, el **RMSE** es 0 en este caso, pues por la naturaleza del modelo, nos interesa que el modelo coincida con los valores observados en los puntos correspondientes cada semana.

En la tabla hemo redondeado los errores a dos cifras decimales.

Tabla 3: RMSE para los modelos 1 y 2

	SINT	HOSP	DEF
LOWESS	121.58	54.62	7.03
PCHIP	0.00	0.00	0.00

Vemos entonces que por diseño del modelo, PCHIP es quien no solo aproxima mejor los datos, sino que los interpola, en este sentido, nuestro modelo esta aprendiendo los datos, lo cual podría no ser la mejor opción si nuestro interes es predecir un aproximado del número de casos para las semanas sin reportes. LOWESS es entonces una opción más adecuada, pues aprende mejor las tendencias de la serie temporal.

e) Totales y comparación

Calcularemos el total acumulado de hospitalizaciones y defunciones.

En la tabla hemos redondeado el total de casos a cero cifras decimales.

Tabla 4: Casos acumulados para los diferentes modelos

	Datos Originales	PCHIP	LOWESS
HOSP	6588	6956	6864
DEF	687	729	751