

Tarea 9

Hospitalizaciones y defunciones semanales

Filtrado de los datos

```
# Importamos las librerías necesarias
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
plt.rcParams['text.usetex'] = True
import seaborn as sns
from statsmodels.nonparametric.smoothers_lowess import lowess
from scipy.interpolate import PchipInterpolator
```

Simbología

- CASOS_SINT = casos sintomáticos
- CASOS_HOSP = casos hospitalizaciones
- CASOS_DEF = casos defunciones

```
df = pd.read_csv("influenza_glm_ready.csv") # Importamos el dataset
influenza = df[['SEMANA_RELATIVA', "CASOS_SINT", "CASOS_HOSP", "CASOS_DEF",
                'FLAG_SINT', 'FLAG_HOSP', 'FLAG_DEF']] # Filtramos los datos de
nuestro interés.
estilo_tabla = (influenza.head(5).style
                .set_properties(**{'text-align': 'center'})
                .hide(axis='index')
                .set_caption("Resumen de los datos de Influenza")
                .set_table_styles([
                    # ESTILO PARA EL TÍTULO (caption)
                    dict(selector='caption', props=[
                        ('font-size', '15px'),
                        ('padding', '10px')
                    ]),
                    # Estilo para los encabezados
                    dict(selector='th', props=[
                        ('text-align', 'center'),
                        ('background-color', '#f2f2f2'),
                        ('font-size', '11px'),
                        ('padding', '5px')
                    ])
                ])
1)
```

```
)
estilo_tabla
```

Tabla 1: Resumen de los datos de Influenza

SEMANA_RELATIVA	CASOS_SINT	CASOS_HOSP	CASOS_DEF	FLAG_SINT	FLAG_HOSP	FLAG_DEF
1	134	40	5	observado	observado	observado
2	145	62	8	observado	observado	observado
3	162	71	9	observado	observado	observado
4	125	58	8	observado	observado	observado
5	102	49	3	observado	observado	observado

Inspección de los datos

```
plt.rcParams['figure.dpi'] = 300
fig, ax = plt.subplots(3, figsize = (10,7))
colors = ['#3f64a1', '#f5425a']

casos = ["SINT", "HOSP", "DEF"]

for i in range(3):
    sns.scatterplot(
        data=influenza,
        x = "SEMANA_RELATIVA",
        y = "CASOS_" + casos[i],
        hue = "FLAG_" + casos[i],
        palette = colors,
        ax = ax[i]
    )
    ax[i].set_xticks([1, 10, 20, 30, 40, 50])
    ax[i].set_xlabel(None)
    ax[i].tick_params(axis='both', which='major', labelsize=12)
    ax[i].legend(prop={'size': 13})


fig.supxlabel("SEMANA RELATIVA")

ax[0].set_ylabel("SINTOMATICOS")
ax[1].set_ylabel("HOSPITALIZACIONES")
ax[2].set_ylabel("DEFUNCIONES")

ax[0].set_xticklabels([])
ax[1].set_xticklabels([])

fig.suptitle("Casos por semana")
#fig.text(1,1,"Hola")
```

```
plt.tight_layout()
plt.show()
```



a) Preprocesamiento

Semanas con datos faltantes o no reportados

```
# Filtramos aquellas semanas para las cuales una de las "FLAGS" aparece como
no_reportado
NoReportes = influenza[(influenza["FLAG_SINT"] == "sin_reporte") |
                        (influenza["FLAG_HOSP"] == "sin_reporte") |
                        (influenza["FLAG_DEF"] == "sin_reporte")]

def resaltar_sin_reporte(val):
    color = 'cyan' if val == 'sin_reporte' else ''
    return f'background-color: {color}'

estilo_tabla = (
    NoReportes.style
    .hide(axis='index')
    .set_caption("Semanas con al menos uno de los casos etiquetados como
sin_reporte")
)
```

```

.map(resaltar_sin_reporte)
.set_properties(*{'text-align': 'center'})
.set_table_styles([
    # ESTILO PARA EL TÍTULO (caption)
    dict(selector='caption', props=[
        ('font-size', '15px'),
        ('padding', '10px')
    ]),
    # Estilo para los encabezados
    dict(selector='th', props=[
        ('text-align', 'center'),
        ('background-color', '#f2f2f2'),
        ('font-size', '11px'),
        ('padding', '5px')
    ]),
])
)
estilo_tabla

```

Tabla 2: Semanas con al menos uno de los casos etiquetados como sin_reporte

SEMANA_RELATIVA	CASOS_SINT	CASOS_HOSP	CASOS_DEF	FLAG_SINT	FLAG_HOSP	FLAG_DEF
8	62	26	0	observado	observado	sin_reporte
14	0	0	0	sin_reporte	sin_reporte	sin_reporte
15	0	0	0	sin_reporte	sin_reporte	sin_reporte
16	0	0	0	sin_reporte	sin_reporte	sin_reporte
17	0	0	0	sin_reporte	sin_reporte	sin_reporte

b) Modelo 1 - Interpolación

Interpolaremos los datos utilizando un **spline cubico de Hermite**. Para ello emplearemos la función `PchipInterpolator` de la librería `SciPy`

Notas

i) Para los modelos 1 y 2, la interpolación (y regresión) se realizara en los puntos $x_i = i - iésima$ semana relativa tal que hay casos observados. Por lo tanto el intervalo de los datos será $I = [1, 52]$. Luego cada subintervalo $[i, i + 1]$, $1 \leq i \leq 1$ se subdividira en 7 intervalos igualmente espaciados en los cuales se realizaran las predicciones, del modelo correspondiente, dandonos su curva de interpolación o de regresión.

ii) En cada caso se agregara al dataset una columna adicional con el valor retornado por cada modelo, para cada uno de los casos (SINT, HOSP, DEF) tanto para los etiquetados como observado, como para los etiquetados como sin_reporte.

iii) En cada caso las predicciones de los modelos se han redondeado a un entero. Esto para ser consistente con una cantidad entera de casos por día.

```
fig, ax = plt.subplots(3, figsize = (12,12))

casos = ["SINT", "HOSP", "DEF"]
titulos = ["Casos Sintomáticos", "Casos Hospitalizaciones", "Casos Defunciones"]

for i in range(3):
    SemanasConReporte = influenza[influenza["FLAG_" + casos[i]] ==
"observado"]["SEMANA_RELATIVA"]
    SemanasSinReporte = influenza[influenza["FLAG_" + casos[i]] ==
"sin_reporte"]["SEMANA_RELATIVA"]
    CasosObservados = influenza[influenza["FLAG_" + casos[i]] == "observado"]
["CASOS_" + casos[i]]

    PCHIP = PchipInterpolator(SemanasConReporte, CasosObservados)
    X = np.linspace(1, 52, 7*51+1)
    Y = PCHIP(X)
    Imputaciones = PCHIP(SemanasSinReporte)

    ax[i].plot(X, Y, '--', label = "PCHIP", )
    ax[i].plot(SemanasConReporte, CasosObservados, 'k.', label='observaciones
originales')
    ax[i].plot(SemanasSinReporte, Imputaciones, 'kX', label='imputaciones')

    ax[i].grid(True, linestyle='--', alpha=0.7)
    ax[i].set_title(titulos[i], size=15)
    ax[i].set_xticks([1, 10, 20, 30, 40, 50])
    ax[i].set_xlabel(None)


    ax[i].tick_params(axis='both', which='major', labelsize=12)

    influenza["CASOS_" + casos[i] + "_PCHIP"] = np.round(Y[0:7*51+1:7],
decimals=0)

fig.supxlabel("SEMANA RELATIVA", size=15)
fig.suptitle("Interpolación del número de casos para datos de influenza
mediante Spline Cúbico de Hermite", size=15)

ax[0].set_xticklabels([])
ax[1].set_xticklabels([])
ax[0].legend(loc='upper right', fancybox=True, ncols=1, shadow=True,
bbox_to_anchor=(1.3,1), prop={'size': 13})

plt.tight_layout()
plt.show()
```



c) Modelo 2 - Regresión Generalizada

Utilizamos un suavizamiento de la serie de tiempo mediante una regresión robusta local ponderada (LOWESS). Para ello emplearemos la función `lowess` de la librería `statsmodels`.

Este metodo pondera los datos realizando una predicción en el punto x_i de la serie tomando en consideración solo los primeros rN —ésimos vecinos a la derecha de x_i , en donde

- N es el tamaño de los datos.
- $0 < r \leq 1$ correspond a la fracción de los datos sobre los que queremos ponderar respecto a cada x_i .

- El valor de r se escoge según sea conveniente, por ejemplo, disminuyendo los valores residuales. Para este caso utilizaremos el valor de $r = 0.5$ como default, lo cual corresponde a ponderar sobre la mitad de los datos.

```
fig, ax = plt.subplots(3, figsize = (12,12))

casos = ["SINT", "HOSP", "DEF"]
titulos = ["Casos Sintomáticos", "Casos Hospitalizaciones", "Casos Defunciones"]
ErrorModelos = {caso:[0.0] for caso in casos}

for i in range(3):
    SemanasConReporte = influenza[influenza["FLAG_" + casos[i]] ==
    "observado"]["SEMANA_RELATIVA"]
    SemanasSinReporte = influenza[influenza["FLAG_" + casos[i]] ==
    "sin_reporte"]["SEMANA_RELATIVA"]
    CasosObservados = influenza[influenza["FLAG_" + casos[i]] == "observado"]
    ["CASOS_" + casos[i]]

    X = np.linspace(1, 52, 7*51+1)

    Regression = lowess(CasosObservados, SemanasConReporte, xvals=X,
    frac=0.5)

    ax[i].plot(X, Regression, 'r--', label = "LOWESS", )
    ax[i].plot(SemanasConReporte, CasosObservados, 'k.', label='observaciones
    originales')
    ax[i].plot(SemanasSinReporte, Regression[7*SemanasSinReporte.index], 'kX',
    label='imputaciones')

    ax[i].grid(True, linestyle='--', alpha=0.7)
    ax[i].set_title(titulos[i], size=15)
    ax[i].set_xticks([1, 10, 20, 30, 40, 50])

    ax[i].tick_params(axis='both', which='major', labelsize=12)

    # Cálculo del error cuadrático
    ErroresCuadraticos = (CasosObservados[SemanasConReporte.index] -
    Regression[7*SemanasConReporte.index]) ** 2
    PromedioErrores = np.mean(ErroresCuadraticos)
    RMSE = np.sqrt(PromedioErrores)
    ErrorModelos[casos[i]].insert(0, RMSE)

    influenza["CASOS_" + casos[i] + "_LOWESS"] =
    np.round(Regression[0:7*51+1:7], decimals=0)

ax[0].set_xticklabels([])
```


```

ax[1].set_xticklabels([])

fig.supxlabel("SEMANA RELATIVA")
fig.suptitle("Aproximación del número de casos para datos de influenza
mediante LOWESS con r=0.5", size=15)
ax[0].legend(loc='upper right', fancybox=True, ncol=1, shadow=True,
bbox_to_anchor=(1.3,1), prop={'size': 13})

plt.tight_layout()
plt.show()

```



d) Errores de Estimación

Dado que nos interesa saber que tan bien se ajusta la interpolación y la regresión a nuestros datos observados, conviene saber que tan dispersos están de la curva obtenida. Por lo que utilizaremos la Raíz del Error Cuadrático Medio (**RMSE**)

$$\sqrt{\frac{1}{n} \sum (\hat{y}_i - y_i)^2}$$

La cual nos da la desviación estándar de los valores residuales. Notemos que en el caso del Modelo 1, que consistió en interpolar los datos, el **RMSE** es 0 en este caso, pues por la naturaleza del modelo, nos interesa que el modelo coincida con los valores observados en los puntos correspondientes cada semana.

```
df = pd.DataFrame(ErrorModelos)
df.index = ["LOWESS", "PCHIP"]
estilo_tabla = (
    df.style
    .set_caption("RMSE para los modelos 1 y 2")
    .map(resaltar_sin_reporte)
    .set_properties(**{'text-align': 'center'})
    .set_table_styles([
        # Estilo para los encabezados (th)
        dict(selector='th', props=[('text-align', 'center'), ('background-
color', '#f2f2f2')]),

        # ESTILO PARA EL TÍTULO (caption)
        dict(selector='caption', props=[
            ('font-size', '15px'),      # Aquí ajustas el tamaño (ej. 20px,
1.5em, etc.)
            ('padding', '10px')        # Opcional: espacio entre el título y la
tabla
        ])
    ])
    .format(precision=2)
)

estilo_tabla
```

Tabla 3: RMSE para los modelos 1 y 2

	SINT	HOSP	DEF
LOWESS	121.58	54.62	7.03
PCHIP	0.00	0.00	0.00

Vemos entonces que por diseño del modelo, PCHIP es quien no solo aproxima mejor los datos, sino que los interpola, en este sentido, nuestro modelo está aprendiendo los datos, lo cual podría

no ser la mejor opción si nuestro interés es predecir un aproximado del número de casos para las semanas sin reportes. LOWESS es entonces una opción más adecuada, pues aprende mejor las tendencias de la serie temporal.

e) Totales y comparación

Calcularemos el total acumulado de hospitalizaciones y defunciones.

```
modelos = ["PCHIP", "LOWESS"]
casos = ["HOSP", "DEF"]
index = ["Hospitalizaciones", "Defunciones"]

CasosAcumulados = {"Datos Originales": [], "PCHIP": [], "LOWESS": []}

for caso in casos:
    N = influenza["CASOS_" + caso].sum()
    CasosAcumulados["Datos Originales"].append(N)

for modelo in modelos:
    for caso in casos:
        N = influenza["CASOS_" + caso + "_" + modelo].sum()
        CasosAcumulados[modelo].append(N)

CasosAcumulados = pd.DataFrame(CasosAcumulados)
CasosAcumulados.index = casos

estilo_tabla = (
    CasosAcumulados.style
    .set_caption("Casos totales acumulados para los diferentes modelos y casos")
    .map(resaltar_sin_reporte)
    .set_properties(**{'text-align': 'center'})
    .set_table_styles([
        # Estilo para los encabezados (th)
        dict(selector='th', props=[('text-align', 'center'), ('background-color', '#f2f2f2)]),

        # ESTILO PARA EL TÍTULO (caption)
        dict(selector='caption', props=[
            ('font-size', '15px'),    # Aquí ajustas el tamaño (ej. 20px, 1.5em, etc.)
            ('padding', '10px')      # Opcional: espacio entre el título y la tabla
        ])
    ])
    .format(precision=0)
)
```

estilo_tabla

Tabla 4: Casos totales acumulados para los diferentes modelos y casos

	Datos Originales	PCHIP	LOWESS
HOSP	6588	6955	6865
DEF	687	728	753

Comparando los datos podemos notar que el modelo PCHIP predice más hospitalizaciones respecto al modelos LOWESS. Por otra parte, el modelo LOWESS predice mayor número de defunciones respecto al modelo PCHIP

Bonus


Crearemos un dataframe llamado HospAcumuladas para guardar la serie de hospitalizaciones acumuladas, relleno con las predicciones del modelo LOWESS.

```
HospAcumuladas = influenza[["CASOS_HOSP_LOWESS"]].cumsum()
HospAcumuladas = HospAcumuladas.rename(columns={"CASOS_HOSP_LOWESS":
"HOSP_ACUMULADAS"})
HospAcumuladas.index = influenza["SEMANA_RELATIVA"]

fig, ax = plt.subplots(figsize = (10,5))
colors = ['#3f64a1', '#f5425a']

sns.scatterplot(
    data=HospAcumuladas,
    x = "SEMANA_RELATIVA",
    ax = ax
)
ax.set_xticks([1, 10, 20, 30, 40, 50])
sns.scatterplot(HospAcumuladas)
fig.suptitle("Hospitalizaciones Acumuladas en base al modelo LOWESS")
plt.show()
```

Hospitalizaciones Acumuladas en base al modelo LOWESS



B1) Ajuste del modelo acumulado

Aproximaremos la serie de tiempo mediante una curva logistica

$$F(t; K, r, t_0) = \frac{K}{1 + e^{-r(t-t_0)}}$$

en donde t es un punto en el tiempo, K es la capacidad máxima, r la tasa de crecimiento, y t_0 el punto de inflexión.

Nuestro objetivo es aproximar aquellos valores de K , r y t_0 que minimicen el error cuadrático entre las predicciones y los datos observados. Para ello emplearemos la función `least_squares` de la librería `scipy.optimize`.

Representaremos los parámetros como un arreglo θ en donde

- $\theta(0) = K$
- $\theta(1) = r$
- $\theta(2) = t_0$

La función trabaja a partir de un estimado dado de los parámetros, en este caso utilizaremos las estimaciones - $K = 7000$ que es un valor moderadamente mayor al total de casos acumulados predichos por LOWESS - $r = 2$ - $t_0 = 24$ la semana en la que visualmente se tiene el punto de inflexión de los datos.

```
from scipy.optimize import least_squares
```

```

# Definimos la función de la curva logística
def F(theta, t):
    return theta[0] / (1 + np.exp(- theta[1] * (t - theta[2])))

# Declaramos los puntos de la serie de tiempo, la semanas relativas en este caso
ts = np.array(HospAcumuladas.index)
ys = np.array(HospAcumuladas["HOSP_ACUMULADAS"])

# Definimos nuestra función de costo o de valores residuales
def residuales(theta):
    return F(theta, ts) - ys

theta = [7000, 2, 24]
res = least_squares(residuales, theta)

# Imprimimos los parametros obtenidos
print("Los parametros obtenidos son:")
print(f"K = {res.x[0]}")
print(f"r = {res.x[1]}")
print(f"t_0 = {res.x[2]}")

```

```

Los parametros obtenidos son:
K = 6872.716122052255
r = 0.166657706798571
t_0 = 24.60893448341319

```

Redondearemos los parametros de manera que - $K = 6872$ - $r = 0.17$ - $t_0 = 24.61$

```

fig, ax = plt.subplots(figsize = (10,6))

K = 6872
r = 0.17
t0 = 24.61
theta = [K, r, t0]


# Calculamos los valores predichos por la curva logística obtenida
Y = [F(theta, t) for t in ts]
ax.plot(ts, Y, '-', color='orange', label="modelo logístico F(t)")
ax.plot(ts, ys, 'k.', label="observaciones")

ax.set_xticks([1, 10, 20, 30, 40, 50])
ax.set_xlabel("Semana Relativa", size=15)
ax.tick_params(axis='both', which='major', labelsize=12)
ax.set_title("Modelo acumulado del número de hospitalizaciones mediante un
función logística mediante una función logística", size=15)
ax.legend(prop={'size': 13})

```

```
plt.legend()
plt.show()
```

Modelo acumulado del número de hospitalizaciones mediante un función logística mediante una función logística



Tenemos según lo anterior que la curva logística esta dada por


$$F(t) = \frac{6872}{1 + e^{-0.17(t-24.61)}}$$

Graficaremos ahora los valores residuales

```
fig, ax = plt.subplots(figsize = (10,6))

ax.hlines(0, 1, 52, linestyle='dashed', color='black')
ax.plot(ts, residuales(theta), 'o', color='orange', label="residuales")

ax.set_xticks([1, 10, 20, 30, 40, 50])
ax.set_xlabel("Semana Relativa", size=15)
ax.tick_params(axis='both', which='major', labelsize=12)
ax.set_title("Valores residuales del modelo logístico", size=15)
ax.legend(prop={'size': 13})
plt.legend()
plt.show()
```



B2) Algoritmo de detección temprana del pico epidémico

Recordemos que

- $K = 6872$
- $r = 0.17$
- $t_0 = 24.61$

i) Estimación de $f'(t) = F'(t)$

Derivando directamente llegamos a que

$$f(t) = F'(t) = rK \frac{e^{-r(t-t_0)}}{(1 + e^{-r(t-t_0)})^2}$$

Haciendo

$$p = \frac{K}{1 + e^{-r(t-t_0)}}$$

tenemos que

$$e^{-r(t-t_0)} = \frac{K}{p} - 1$$

luego

$$-r(t - t_0) = \ln\left(\frac{K}{p} - 1\right)$$

finalmente

$$Q(p) = F^{-1}(p) = -\frac{1}{r} \ln\left(\frac{K}{p} - 1\right) + t_0 = t$$

Implementando estas funciones a código se tiene que

```
def f(theta, t):
    exponent = - theta[1] * (t - theta[2])
    exp_val = np.exp(exponent)
    resultado = theta[1] * theta[0] * (exp_val / (1 + exp_val)**2)
    return resultado

def Q(theta, p):
    return (-1 / theta[1]) * np.log((theta[0] / p) - 1) + theta[2]
```

```
F(theta, 1)
```

```
np.float64(121.94928926262486)
```

```
ys[0]
```

```
np.float64(11.0)
```

Podemos entonces definir

$$Q(p) = F^{-1}(p) \quad p \in [122, K)$$

el intervalo empieza en 121 ya que es el redondeo del número de casos predicho por el modelo logístico durante la primera semana.


```
fig, ax = plt.subplots(figsize = (10,6))

P = np.arange(122, K, 1)
Y = [Q(theta, p) for p in P]
ax.plot(P, Y, '-', color='orange', label="Semana Relativa")

ax.set_xticks([122, 1000, 2000, 3000, 4000, 5000, 6000, 7000])
ax.set_xlabel("Casos Acumulados", size=15)
ax.tick_params(axis='both', which='major', labelsize=12)
ax.set_title("Inversa del modelo logístico para hospitalizaciones acumuladas",
```



```
size=15)
ax.legend(prop={'size': 13})
plt.legend()
plt.show()
```



ii) $Q'(p)$ y $Q''(p)$ sobre una malla de valores de p

A partir de los resultados anteriores podemos definir explícitamente quien es $Q'(p)$, y de manera numérica quien es $Q''(p)$.

La malla de valores de p la construiremos tomando unicamente valores enteros para p , en el intervalo $(122, K]$ será sobre esta misma malla que estimaremos la segunda derivada de Q empleando la función `derivate` de la librería `scipy.differentiate`, aplicada a la función `dQ(p)` implementada en python, correspondiente a $Q'(p)$.

```
# definción de dQ(p) = Q'(p)

def dQ(p):
    return 1 / f(theta, Q(theta, p))
```

Mostraremos la gráfica de $Q''(x)$ tomando escala logarítmica en el eje Y

```

from scipy.differentiate import derivative
# definimos la malla de valores para p


mallaP = np.arange(122, K, 1)

# Calculamos la segunda derivada de Q sobre mallaP
ddQ = derivative(dQ, mallaP)

fig, ax = plt.subplots(figsize = (10,6))

ax.plot(mallaP, ddQ.df, '-', color='orange', label=r"$Q''(p)$")
ax.set_ylim(-0.001, 0.001)
ax.set_xticks([122, 1000, 2000, 3000, 4000, 5000, 6000, 7000])
ax.set_xlabel("Casos Acumulados", size=15)
ax.set_title("Segunda derivada del modelo logístico para hospitalizaciones acumuladas", size=15)
ax.tick_params(axis='both', which='major', labelsize=12)
ax.legend(prop={'size': 13})
plt.legend()
plt.show()

```



Parar una mejor visualización del punto de inflexión hemos restringido el eje Y al intervalo $[-10^{-3}, 10^3]$.

iii) Primera inflexión del modelo logístico

Podemos ahora iterar sobre la malla de p e identificar el momento justo antes del punto de inflexión

```
p_inflexion = 0
for i in range (len(ddQ.df)):
    if ddQ.df[i+1] > 0 :
        p_inflexion = i + 122
        break

print(f"La primera inflexión se da en p = {p_inflexion}")
```

La primera inflexión se da en p = 3436

Tenemos entonces que para una cantidad acumulada de hospitalizaciones de $p^* = 3436$ se da la primera inflexión.

iv) De regreso a la escala temporal

Aplicando F^{-1} , y redondeando al entero más cercano obtenemos que

```
t_inflexion = np.round(Q(theta, p_inflexion))
print(f"pico epidémico t = {t_inflexion}")
```

pico epidémico t = 25.0

La semana de inicio del pico corresponde a $t^* = F^{-1}(p) \approx 25$.

v) Gráfica del inicio del pico

```
fig, ax = plt.subplots(nrows=2, figsize = (10,15))

YdQ = [dQ(p) for p in P]
YddQ = ddQ.df
ax[0].scatter([p_inflexion], [ddQ.df[p_inflexion-121]], [100], marker="*",
color='black', label=r"$p^{\ast}$",zorder=3)
ax[0].plot(mallaP, YdQ, '-', color='blue', alpha=0.6, label=r"$Q'(x)$",
linewidth=4,zorder=1)
ax[0].plot(mallaP, YddQ, '-', color='orange', alpha=0.6, label=r"$Q''(x)$",
linewidth=4,zorder=2)
ax[0].set_xticks([122, 1000, 2000, 3000, 4000, 5000, 6000, 7000])
ax[0].set_xlabel("Casos Acumulados", size=15)
ax[0].set_title("Primera y segunda derivada de la inversa de la curva
epidémica", size=15)



Y = [F(theta, t) for t in ts]
```

```

ax[1].plot(ts, Y, '-', color='orange', linewidth=4, label=r"curva epidemica
$F(t)$")
ax[1].scatter([t_inflexion], [F(theta, t_inflexion)], [100], marker="*",
color='black', label=r"$t^{\ast}$",zorder=3)
ax[1].set_xticks([1, 10, 20, 30, 40, 50])
ax[1].set_xlabel("Semana Relativa", size=15)
ax[1].set_ylabel("Casos Acumulados", size=15)
ax[1].set_title("Inicio del pico epidémico", size=15)

ax[0].tick_params(axis='both', which='major', labelsize=12)
ax[1].tick_params(axis='both', which='major', labelsize=12)
ax[1].legend(prop={'size': 13})
ax[0].legend(prop={'size': 13})
plt.show()

```



Se tiene entonces que la semana de inicio del pico epidemico coincide visualmente con los datos. De manera analítica esto coincide con que t_0 es precisamente el punto de inflexión del modelo logístico, en este caso, ya conocíamos que $t_0 \approx 24 \approx 25$.

En conclusión, podemos decir finalmente, que el inicio del pico epidémico comienza durante la semana 25.